

EAGLE3 + Qwen3VL

训练：

路径： /mnt/beegfs/groups/cv/jiajun.lu/SpecForge_yuboyang

环境： /mnt/beegfs/groups/cv/yuboyang/anaconda3/envs/sglang

1. 数据预处理：

/mnt/beegfs/groups/cv/jiajun.lu/SpecForge_yuboyang/scripts/fix_toon_data.py

2. 训练： ./examples/run_weather.sh

3. 模型： ./outputs/Qwen3-VL-nio-2b-eagle3/epoch_3

测试：

路径： /mnt/beegfs/groups/cv/jiajun.lu/sglang_yuboyang

环境： /mnt/beegfs/groups/cv/yuboyang/anaconda3/envs/sglang_eval

测试： ./test_sclang_withbenchmark.py

实验结果汇总 EAGLE3

Base model = /mnt/beegfs/groups/cv/yuboyang/data/qwen3_nio_2b

测试集： _toon前100条数据

speculative-num-steps_speculative-eagle-topk_speculative-num-draft-tokens

Tree_structure	prefill_latency (s)	spec_accept_rate (%)	e2e_latency (s)	compress ratio (↑)
ep=9				
chain_structure 8node 8_1_8	0.21	31	0.64	3.47
chain_structure 5node	0.42	40	1.28	3.04
5_2_8	0.21	43	0.83	3.13

8_2_8	0.24	27.8	0.67	3.23
8_3_8	0.21	29.5	0.65	3.32
8_2_16	0.21	34.4	0.61	3.73
8_3_16	0.21	34.7	0.65	3.71
5_4_16	0.21	46.7	0.63	3.27
6_3_16	0.21	38.8	0.63	3.34
10_2_16	0.27	28	1.02	3.86
10_2_32	0.21	34	1.02	4.31
10_3_32	0.21	31	0.63	4.05
8_3_32	0.21	36	0.66	3.82
6_5_32	0.21	40	0.63	3.41
6_10_32	0.21	42	0.63	3.56
ep=3				
8_3_8				3.4
8_2_16				3.9
4_4_16 (vs medusa)	0.21	51	0.63	3.02
4_2_14 (vs medusa)	0.21	48	0.65	2.91
16_1_16				3.71
12_2_16	0.29	24.8	0.81	3.93
12_3_32				4.2
12_2_32				4.15
8_4_32				4.17
9_4_32				4.04

一个观察：在加速比低的情况下，EAGLE3在sglang下跑出了210.39 tokens/s的decoding，远高于Medusa的43。证明对于2b级别的模型，推理框架对性能的提高超过了投机算法本身。

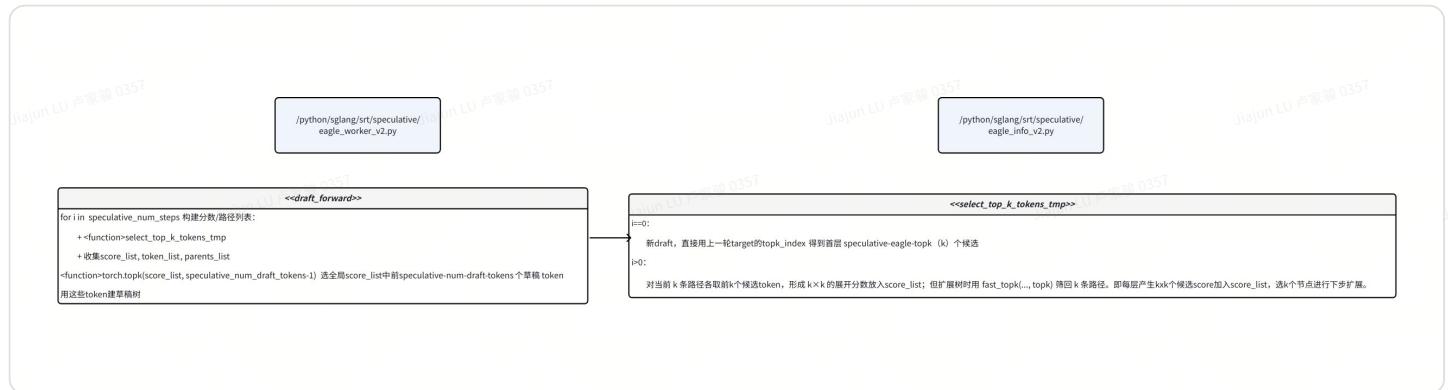
三个参数的具体作用

speculative-num-steps: 可能的最大树深

speculative-eagle-topk: 每层保留/向下扩展的路径数, 展开时每条路径取 topk, 形成 $k \times k$ 展开, 再筛选 k 条路径继续。

speculative-num-draft-tokens: 草稿树最终token数

具体流程:



对参数的理解

1. 简单数据, 建议 $\text{topk} \leq 3$, 把更多节点分配给深度。

speculative-num-steps 仅为理论最大树深, 不代表实际。实际树深仅由全局选出 **speculative-num-draft-tokens** 个 token 形成的草稿树唯一决定。由于每个候选节点的 score = 根到该节点路径上各步的 softmax 概率之积, 因此当 topk 过大时, 会挤占 token 数, 影响树深。

不挤占树深时, 仍建议 $\text{topk} \leq 3$ 。观察实验, 加速比 $10_2_32 > 10_3_32$ 。注意到这两种结构下 node 均盈余, 树为每层 2 or 3 node、10 层。而树每层多一个节点但加速比反降。WHY?

结论: $\text{topk} \neq \text{树宽!}$ 最终树结构由且仅由全局 score_list 召回的前 num-draft-tokens 个 token 决定。注意到 score_list 中包含的是 $k + (\text{num-steps}-1)k^*k$ 个 token。由概率的链乘特性, 可能有:

P(第 i 层的 rank4 节点) > P(第 i+1 层的 rank3 节点)。挤占名额, 影响树深。